



Tecnológico de Monterrey

3.2 Proyecciones

Federico Alberto Vinatier Villarreal A00838009

Series de tiempo.

Grupo #102

Prof. Raymundo Diaz

04/03/2025

Link de colab:

https://colab.research.google.com/drive/1r9P7fz_BsTiBPH5APOjW4vGxJ9LU35ac?usp=sharing

Linke de github: <https://github.com/Federicoavv03/Series-de-tiempo>

Prompt de Grok: https://grok.com/share/bGVnYWN5_e5b033f7-579e-4f33-a724-d862295bd5f4

En relación con el ejercicio:

NOTA: Para este ejercicio utilicé las acciones de Apple (AAPL) y Microsoft (MSFT), a continuación se presentan los resultados.

Determinar la presencia de tendencia principal y estacionalidad en los datos.

- **Tendencia principal:** Sí, ambas series (AAPL y MSFT) muestran una tendencia clara, como indica la no estacionariedad (ADF y KPSS) y el gráfico, que muestra una tendencia descendente general a corto plazo (pronósticos y visualización).
- **Estacionalidad:** No hay evidencia de estacionalidad en los datos, ya que los modelos ARIMA no incluyen términos estacionales, y los gráficos no muestran patrones cíclicos evidentes. Para confirmarlo, necesitaríamos un análisis adicional (ej. ACF, descomposición STL).

Determinar si los datos son estacionarios.

No, los datos de AAPL y MSFT no son estacionarios. Esto se confirma con:

- ADF: p-valores > 0.05 (no rechazan no estacionariedad).
- KPSS: p-valores < 0.05 (rechazan estacionariedad).
- Modelos ARIMA: Requieren diferencias ($d=1$ o $d=2$) para alcanzar estacionariedad.

Dividir los datos en entrenamiento (90%) y prueba (10%).

- Train: 1188 observaciones (90%, índices 0-1187).
- Test: 132 observaciones (10%, índices 1188-1319).

Resultados:

- Los datos de entrenamiento son no estacionarios (igual que los datos completos).
- Modelos ARIMA ajustados en entrenamiento: AAPL (0,1,0), MSFT (2,1,2).
- Pronósticos evaluados con MSE: AAPL (274.89), MSFT (1011.65).

RESULTADOS DESPUÉS DE AJUSTE

Después de haber ajustado el modelo, se obtuvieron los siguientes resultados:

- **Tendencia principal:** Sí, ambas series (AAPL y MSFT) muestran una tendencia clara, como indica la no estacionariedad de los datos originales (pruebas ADF/KPSS) y los gráficos, que sugieren una tendencia general (probablemente ascendente a largo plazo, pero descendente a corto plazo según pronósticos).
- **Estacionalidad:** Aunque la descomposición STL detectó "Possible seasonality", el componente estacional probablemente sea pequeño (no significativo para precios diarios de acciones). Si los gráficos de STL muestran una desviación estándar del componente estacional $< 10\%$ de la serie original, no hay estacionalidad detectable. Para confirmarlo, revisa los gráficos de STL; si no hay patrones cíclicos claros, asumimos que no hay estacionalidad significativa.
- Los datos originales de AAPL y MSFT no son estacionarios:
 - Pruebas ADF: p-valores > 0.05 (no rechazan no estacionariedad).
 - Pruebas KPSS: p-valores < 0.05 (rechazan estacionariedad).
- Los datos diferenciados dos veces ($d=2$) **son estacionarios**:
 - Pruebas ADF: p-valores $= 0.0000$ (< 0.05 , rechazan no estacionariedad).
 - Pruebas KPSS: p-valores $= 0.1000$ (> 0.05 , no rechazan estacionariedad).
- Esto confirma que la diferenciación ($d=2$) eliminó la tendencia y estabilizó las series.

3. Split the data in train (90%) and test (10%)

- **Implementación:** Dividimos los datos en:
 - **Train:** 1188 observaciones (90%, índices 0-1187).
 - **Test:** 132 observaciones (10%, índices 1188-1319).
- Para las series diferenciadas:
 - **Train:** 1186 observaciones (90%, debido a 2 NaN eliminados por `diff().diff()`).
 - **Test:** 132 observaciones (ajustadas para mantener la proporción).
- **Resultados:**
 - Los datos de entrenamiento diferenciados son estacionarios.
 - Modelos ARIMA ajustados: AAPL (0,0,1), MSFT (2,0,1).
 - Pronósticos evaluados con MSE: AAPL (270.75), MSFT (1061.93).